

# 第 3 章 线性方程组的数值解法

本章主要内容：

- (1) Gauss 消去法, Gauss 列主元消去法
- (2) 方程组的性态和误差估计
- (3) 迭代法 (Jacobi、Gauss-Seidel、SOR 迭代)
- (4) 幂法和反幂法

# 1 Gauss 消去法

思想：利用线性代数中的初等行变换将方程组化为等价的三角形方程组.

## 1.1 三角形方程组的回代法

考虑三角形方程组

$$\begin{array}{ccccccc} u_{11}x_1 + & u_{12}x_2 + & \cdots + & u_{1,n-1}x_{n-1} + & u_{1n}x_n & = & y_1 \\ & u_{22}x_2 + & \cdots + & u_{2,n-1}x_{n-1} + & u_{2n}x_n & = & y_2 \\ & & \ddots & \cdots & \cdots & & \\ & & & & u_{n-1,n-1}x_{n-1} + & u_{n-1,n}x_n & = y_{n-1} \\ & & & & & u_{nn}x_n & = y_n \end{array}$$

其中  $u_{ii} \neq 0 (i = 1, 2, \cdots, n)$ . 用下面的回代法求解:

$$\begin{aligned} x_n &= y_n / u_{nn}, \\ x_i &= \left( y_i - \sum_{j=i+1}^n u_{ij}x_j \right) / u_{ii}, \quad i = n-1, n-2, \cdots, 1. \end{aligned}$$

## 1.2 Gauss 消去法

考虑一般的线性方程组

$$\mathbf{A}\mathbf{x} = \mathbf{b}, \quad (1.1)$$

其中

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

将方程  $\mathbf{A}\mathbf{x} = \mathbf{b}$  用增广矩阵表示, 记

$$\bar{\mathbf{A}}^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} & a_{2,n+1}^{(1)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} & a_{n,n+1}^{(1)} \end{bmatrix},$$

其中

$$a_{ij}^{(1)} = a_{ij}, \quad i, j = 1, 2, \cdots, n,$$

$$a_{i,n+1}^{(1)} = b_i, \quad i = 1, 2, \dots, n.$$

下面用  $n - 1$  步消元（初等行变换）将矩阵  $\bar{\mathbf{A}}^{(1)}$  化为上三角矩阵.

(1) **第 1 步消元：** 假设  $a_{11}^{(1)} \neq 0$  (否则交换两行的位置), 记  $l_{i1} = \frac{a_{i1}^{(1)}}{a_{11}^{(1)}}$ ,

第 1 行乘  $-l_{i1}$  加到第  $i$  ( $2 \leq i \leq n$ ) 行得

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & a_{n2}^{(2)} & \cdots & a_{nn}^{(2)} & a_{n,n+1}^{(2)} \end{bmatrix}$$

其中

$$a_{ij}^{(2)} = a_{ij}^{(1)} - l_{i1}a_{1j}^{(1)}, \quad i = 2, 3, \dots, n, \quad j = 2, 3, \dots, n + 1.$$

(2) **第 2 步消元：** 假设  $a_{22}^{(2)} \neq 0$  (否则交换两行的位置), 记  $l_{i2} = \frac{a_{i2}^{(2)}}{a_{22}^{(2)}}$ ,

第 2 行乘  $-l_{i2}$  加到第  $i$  ( $3 \leq i \leq n$ ) 行得

$$\bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & a_{3n}^{(3)} & \cdots & a_{nn}^{(3)} & a_{n,n+1}^{(3)} \end{bmatrix}$$

其中

$$a_{ij}^{(3)} = a_{ij}^{(2)} - l_{i2}a_{2j}^{(2)}, \quad i = 3, 4, \cdots, n, \quad j = 3, 4, \cdots, n+1.$$

(3) 假设按上面进行了  $k-1$  步消元, 即有

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \cdots \longrightarrow \bar{\mathbf{A}}^{(k)},$$

其中

$$\bar{\mathbf{A}}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2,k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n+1}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n+1}^{(k)} \end{bmatrix}$$

(4) 第  $k$  步消元: 假设  $a_{kk}^{(k)} \neq 0$  (否则交换两行的位置), 记  $l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$ , 第  $k$  行乘  $-l_{ik}$  加到第  $i$  ( $k+1 \leq i \leq n$ ) 行得

$$\bar{\mathbf{A}}^{(k)} \longrightarrow \bar{\mathbf{A}}^{(k+1)}$$

$$= \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k}^{(1)} & a_{1,k+1}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k}^{(2)} & a_{2,k+1}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k}^{(3)} & a_{3,k+1}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{kk}^{(k)} & a_{k,k+1}^{(k)} & \cdots & a_{k,n}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k+1}^{(k+1)} & \cdots & a_{k+1,n}^{(k+1)} & a_{k+1,n+1}^{(k+1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+2,k+1}^{(k+1)} & \cdots & a_{k+2,n}^{(k+1)} & a_{k+2,n+1}^{(k+1)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{n,k+1}^{(k+1)} & \cdots & a_{nn}^{(k+1)} & a_{n,n+1}^{(k+1)} \end{bmatrix}$$

其中

$$\begin{aligned} a_{ij}^{(k+1)} &= a_{ij}^{(k)} - l_{ik}a_{kj}^{(k)}, \\ i &= k+1, k+2, \cdots, n, \quad j = k+1, k+2, \cdots, n+1. \end{aligned} \quad (1.2)$$

(5) 总共进行  $n-1$  步 ( $k=1, 2, \cdots, n-1$ ) 消元后,

$$\bar{\mathbf{A}}^{(1)} \longrightarrow \bar{\mathbf{A}}^{(2)} \longrightarrow \bar{\mathbf{A}}^{(3)} \longrightarrow \cdots \longrightarrow \bar{\mathbf{A}}^{(k)} \longrightarrow \cdots \longrightarrow \bar{\mathbf{A}}^{(n)},$$

其中

$$\bar{\mathbf{A}}^{(n)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ & & \ddots & \vdots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} & a_{n-1,n+1}^{(n-1)} \\ & & & & a_{nn}^{(n)} & a_{n,n+1}^{(n)} \end{bmatrix}. \quad (1.3)$$



若记

$$U = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1,n-1}^{(1)} & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2,n-1}^{(2)} & a_{2n}^{(2)} \\ & & \ddots & \vdots & \vdots \\ & & & a_{n-1,n-1}^{(n-1)} & a_{n-1,n}^{(n-1)} \\ & & & & a_{nn}^{(n)} \end{bmatrix}, \quad y = \begin{bmatrix} a_{1,n+1}^{(1)} \\ a_{2,n+1}^{(2)} \\ \vdots \\ a_{n-1,n+1}^{(n-1)} \\ a_{n,n+1}^{(n)} \end{bmatrix},$$

则 (1.3) 对应的线性方程组为  $Ux = y$ , 用回代可求得  $x$ .

可以估计, Gauss 消元法解线性方程组 (1.1) 需要加法和乘法次数均为  $O(n^3)$ .

**定理 1.1** 给定线性方程组  $Ax = b$ . 如果  $A$  的各阶顺序主子式非零, 则 Gauss 消去法中的各主元  $a_{kk}^{(k)} (k = 1, 2, \dots, n)$  均非零.

## 1.3 三对角方程组的追赶法

考虑三对角方程组

$$\begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & \cdots & \cdots & \cdots \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix} \quad (1.4)$$

其系数矩阵元素满足

- (1)  $|b_1| > |c_1| > 0$ ;
- (2)  $|b_i| \geq |a_i| + |c_i|, \quad a_i c_i \neq 0 (i = 2, 3, \cdots, n-1)$ ;
- (3)  $|b_n| > |a_n| > 0$ .

易证 (1.4) 的系数矩阵非奇异. 利用 Gauss 消去法解方程组 (1.4), 每步消元只要消一个元素.

消元过程算法如下:

$$\beta_1 = b_1, \quad y_1 = d_1,$$

对  $i = 2, 3, \dots, n$  计算

$$l_i = \frac{a_i}{\beta_{i-1}}, \quad \beta_i = b_i - l_i c_{i-1}, \quad y_i = d_i - l_i y_{i-1}.$$

回代算法:

$$x_n = y_n / \beta_n,$$

对  $i = n - 1, n - 2, \dots, 1$  计算

$$x_i = (y_i - c_i x_{i+1}) / \beta_i.$$

## 1.4 列主元 Gauss 消去法

由 (1.2) 看出, 在 Gauss 消去法中, 当  $|l_{ik}|$  很大 (如  $|a_{kk}^{(k)}|$  很小) 时, 元素  $a_{kj}^{(k)}$  很小的误差, 将导致元素  $a_{ij}^{(k+1)}$  较大的误差. 所以希望  $|l_{ik}| \leq 1$ . 设进行了  $k-1$  步消元.

$$\bar{A}^{(k)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & \cdots & a_{1,k-1}^{(1)} & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & a_{1,n+1}^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2,k-1}^{(2)} & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & a_{2,n+1}^{(2)} \\ 0 & 0 & a_{33}^{(3)} & \cdots & a_{3,k-1}^{(3)} & a_{3k}^{(3)} & \cdots & a_{3n}^{(3)} & a_{3,n+1}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & a_{k-1,k-1}^{(k-1)} & a_{k-1,k}^{(k-1)} & \cdots & a_{k-1,n}^{(k-1)} & a_{k-1,n+1}^{(k-1)} \\ 0 & 0 & 0 & \cdots & 0 & a_{kk}^{(k)} & \cdots & a_{kn}^{(k)} & a_{k,n+1}^{(k)} \\ 0 & 0 & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & a_{k+1,n+1}^{(k)} \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & a_{n,n+1}^{(k)} \end{bmatrix}$$

在第  $k$  步消元之前, 从第  $k$  列位于对角线以下的元素中选绝对值最大

者作为主元. 如果

$$|a_{sk}^{(k)}| = \max_{k \leq i \leq n} |a_{ik}^{(k)}|,$$

即  $(s, k)$  元素绝对值最大, 则交换第  $s$  行和第  $k$  行对应元素, 然后进行消元. 显然此时有

$$|l_{ik}| = \left| \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} \right| \leq 1.$$

**例 1.1** 用列主元 Gauss 消去法求下列方程组的解.

$$\begin{bmatrix} 3 & 1 & -1 \\ 4 & 0 & 4 \\ 12 & -3 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 8 \\ 9 \end{bmatrix}.$$

## 2 方程组的性态与误差分析

### 2.1 向量范数

设  $\boldsymbol{x} = (x_1, x_2, \dots, x_n)^T \in \mathbf{R}^n$ .

定义 2.1 设  $f(\boldsymbol{x}) = \|\boldsymbol{x}\|$  是  $\mathbf{R}^n$  上的函数, 如果满足:

(1) (非负性)  $\forall \boldsymbol{x} \in \mathbf{R}^n$ , 有  $\|\boldsymbol{x}\| \geq 0$ , 且  $\|\boldsymbol{x}\| = 0 \Leftrightarrow \boldsymbol{x} = \mathbf{0}$ ;

(2) (齐次性)  $\forall \boldsymbol{x} \in \mathbf{R}^n, \lambda \in \mathbf{R}$ , 有  $\|\lambda \boldsymbol{x}\| = |\lambda| \|\boldsymbol{x}\|$ ;

(3) (三角不等式)  $\forall \boldsymbol{x}, \boldsymbol{y} \in \mathbf{R}^n$ , 有  $\|\boldsymbol{x} + \boldsymbol{y}\| \leq \|\boldsymbol{x}\| + \|\boldsymbol{y}\|$ .

则称  $\|\cdot\|$  为  $\mathbf{R}^n$  上的向量范数.

注 2.1 用  $\mathbf{C}^n$  表示所有复的  $n$  维向量组成的复线性空间, 类似可以定义对应的向量范数.

常用的三个向量范数:

(1) 1-范数:  $\|\boldsymbol{x}\|_1 = \sum_{i=1}^n |x_i|$ ;

(2)  $\infty$ -范数:  $\|\boldsymbol{x}\|_\infty = \max_{1 \leq i \leq n} \{|x_i|\}$ ;

$$(3) \text{ 2-范数: } \|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{(\mathbf{x}, \mathbf{x})}.$$

由范数定义的三角不等式易得

$$|\|\mathbf{x}\| - \|\mathbf{y}\|| \leq \|\mathbf{x} - \mathbf{y}\|.$$

**定理 2.1 (向量范数的连续性)** 设  $f(\mathbf{x}) = \|\mathbf{x}\|$  为  $\mathbf{R}^n$  上的任意一个向量范数, 则  $f(\mathbf{x})$  为  $\mathbf{x}$  分量的连续函数. 即

$$\lim_{\mathbf{x} \rightarrow \mathbf{y}} f(\mathbf{x}) = f(\mathbf{y}).$$

**定义 2.2** 设  $\|\cdot\|_p$  和  $\|\cdot\|_q$  是  $\mathbf{R}^n$  上两个范数. 如果存在正常数  $c_1, c_2$  使得对  $\forall \mathbf{x} \in \mathbf{R}^n$ , 有

$$c_1 \|\mathbf{x}\|_p \leq \|\mathbf{x}\|_q \leq c_2 \|\mathbf{x}\|_p,$$

则称范数  $\|\cdot\|_p$  和  $\|\cdot\|_q$  等价.

**定理 2.2 (向量范数的等价性)**  $\mathbf{R}^n$  上任意两个范数都等价.

**定义 2.3** 设  $\|\cdot\|$  是  $\mathbf{R}^n$  上的范数,  $\mathbf{x}, \mathbf{y} \in \mathbf{R}^n$ , 称  $\|\mathbf{x} - \mathbf{y}\|$  为  $\mathbf{x}$  和  $\mathbf{y}$  之间的距离.

利用距离可以研究 2 个向量之间的绝对误差和相对误差. 设  $\boldsymbol{x}^*$ ,  $\tilde{\boldsymbol{x}}$  是方程组  $A\boldsymbol{x} = \boldsymbol{b}$  的精确解和近似解. 则可用  $\|\boldsymbol{x}^* - \tilde{\boldsymbol{x}}\|$  和  $\frac{\|\boldsymbol{x}^* - \tilde{\boldsymbol{x}}\|}{\|\boldsymbol{x}^*\|}$  或  $\frac{\|\boldsymbol{x}^* - \tilde{\boldsymbol{x}}\|}{\|\tilde{\boldsymbol{x}}\|}$  表示近似解  $\tilde{\boldsymbol{x}}$  的绝对误差和相对误差.

**定义 2.4** 设  $\|\cdot\|$  是  $\mathbf{R}^n$  中的一个范数,  $\boldsymbol{x}^{(0)}, \boldsymbol{x}^{(1)}, \boldsymbol{x}^{(2)}, \dots$  是  $\mathbf{R}^n$  中的一个向量序列,  $\boldsymbol{c} \in \mathbf{R}^n$  为常向量. 如果

$$\lim_{k \rightarrow \infty} \|\boldsymbol{x}^{(k)} - \boldsymbol{c}\| = 0,$$

则称向量序列  $\{\boldsymbol{x}^{(k)}\}_{k=0}^{\infty}$  收敛于  $\boldsymbol{c}$ , 记为

$$\lim_{k \rightarrow \infty} \boldsymbol{x}^{(k)} = \boldsymbol{c}.$$



## 2.2 矩阵范数

设

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix},$$

$\|\cdot\|$  为  $\mathbf{R}^n$  上的一个范数.

定义 2.5 称

$$\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}$$

为矩阵  $\mathbf{A}$  的范数, 记为  $\|\mathbf{A}\|$ . 即

$$\|\mathbf{A}\| = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|}.$$

问题: 最大值能否取到?

矩阵范数的性质: 设  $\|\cdot\|$  是一个矩阵范数, 则有

(1)  $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$ ,  $\|\mathbf{A}\| \geq 0$ , 且  $\|\mathbf{A}\| = 0 \Leftrightarrow \mathbf{A} = \mathbf{0}$ .

(2)  $\forall \mathbf{A} \in \mathbf{R}^{n \times n}, \lambda \in \mathbf{R}$ , 有  $\|\lambda \mathbf{A}\| = |\lambda| \|\mathbf{A}\|$ .

(3)  $\forall \mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$ , 有  $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$ .

(4)  $\forall \mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$ , 有  $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$ .

(5)  $\forall \mathbf{A} \in \mathbf{R}^{n \times n}, \mathbf{x} \in \mathbf{R}^n$ , 有  $\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \|\mathbf{x}\|$ .

定义 2.6 设矩阵  $\mathbf{B} \in \mathbf{R}^{n \times n}$ ,  $\lambda_1, \lambda_2, \dots, \lambda_n$  为  $\mathbf{B}$  的  $n$  个特征值. 称

$$\rho(\mathbf{B}) = \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

为矩阵  $\mathbf{B}$  的谱半径.

定理 2.3 设  $\mathbf{A} \in \mathbf{R}^{n \times n}$ , 则

(1)

$$\|\mathbf{A}\|_1 = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1} = \max_{1 \leq j \leq n} \left\{ \sum_{i=1}^n |a_{ij}| \right\}.$$

(2)

$$\|\mathbf{A}\|_\infty = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty} = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\}.$$

(3)

$$\|\mathbf{A}\|_2 = \max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq \mathbf{0}}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} = \sqrt{\rho(\mathbf{A}^T \mathbf{A})}.$$

**定理 2.4** 设  $\|\cdot\|$  是  $\mathbf{R}^{n \times n}$  上的任意一个矩阵范数,  $\mathbf{A} \in \mathbf{R}^{n \times n}$ , 则有

$$\rho(\mathbf{A}) \leq \|\mathbf{A}\|.$$

**定理 2.5** 如果  $\mathbf{A} \in \mathbf{R}^{n \times n}$  为对称矩阵, 则  $\rho(\mathbf{A}) = \|\mathbf{A}\|_2$ .

**定义 2.7** 设  $\|\cdot\|_p$  和  $\|\cdot\|_q$  为  $\mathbf{R}^{n \times n}$  上的两个范数, 如果存在正常数  $c_1, c_2$ , 使得对  $\forall \mathbf{A} \in \mathbf{R}^{n \times n}$  有

$$c_1 \|\mathbf{A}\|_p \leq \|\mathbf{A}\|_q \leq c_2 \|\mathbf{A}\|_p.$$

则称  $\|\cdot\|_p$  和  $\|\cdot\|_q$  等价.

**定理 2.6**  $\mathbf{R}^{n \times n}$  上任意两个矩阵范数都等价.

**定义 2.8** 设  $\|\cdot\|$  是  $\mathbf{R}^{n \times n}$  上的矩阵范数,  $\mathbf{A}, \mathbf{B} \in \mathbf{R}^{n \times n}$ , 称  $\|\mathbf{A} - \mathbf{B}\|$  为  $\mathbf{A}$  与  $\mathbf{B}$  之间的距离.

**定义 2.9** 设  $\|\cdot\|$  是  $\mathbf{R}^{n \times n}$  上的矩阵范数,  $\mathbf{A}^{(0)}, \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(k)}, \dots$  为  $\mathbf{R}^{n \times n}$  上的一个矩阵序列,  $\mathbf{A} \in \mathbf{R}^{n \times n}$ . 如果

$$\lim_{k \rightarrow \infty} \|\mathbf{A}^{(k)} - \mathbf{A}\| = 0,$$

则称矩阵序列  $\{\mathbf{A}^{(k)}\}_{k=0}^{\infty}$  收敛于矩阵  $\mathbf{A}$ , 记为

$$\lim_{k \rightarrow \infty} \mathbf{A}^{(k)} = \mathbf{A}.$$

**定理 2.7** 设  $\mathbf{B} \in \mathbf{R}^{n \times n}$ , 则矩阵序列  $\mathbf{I}, \mathbf{B}, \mathbf{B}^2, \dots, \mathbf{B}^k, \dots$  收敛于零矩阵 (即  $\lim_{k \rightarrow \infty} \mathbf{B}^k = \mathbf{O}$ ) 的充要条件是  $\rho(\mathbf{B}) < 1$ .

## 2.3 方程组的性态和条件数

### 例 2.1 考虑方程组

$$\begin{bmatrix} 1 & -1 \\ 1 & \color{red}{1} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为  $x_1 = x_2 = 1$ .

设方程组系数有小扰动, 方程组成为

$$\begin{bmatrix} 1 & -1 \\ 1 & \color{red}{1.0005} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix},$$

其解为  $x_1 = x_2 = 0.99975006$ .

该例子说明矩阵误差对解的影响不大.

### 例 2.2 考虑方程组

$$\begin{bmatrix} 10 & -10 \\ -1 & \color{red}{1.001} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为  $x_1 = x_2 = 1$ .

同样, 若系数有误差, 方程组变为

$$\begin{bmatrix} 10 & -10 \\ -1 & 1.0015 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.001 \end{bmatrix},$$

其解为  $x_1 = x_2 = \frac{2}{3}$ .

这个例子说明方程组的系数矩阵的误差对解的影响很大. 问题: 怎么判别?

设  $\mathbf{A}$  非奇异,  $\mathbf{b} \neq \mathbf{0}$ , 方程组  $\mathbf{Ax} = \mathbf{b}$  的精确解为  $\mathbf{x}^*$ .

(1) 设  $\mathbf{b}$  有很小的扰动  $\delta\mathbf{b}$ , 此时解  $\mathbf{x}^*$  变为  $\mathbf{x}^* + \delta\mathbf{x}^*$ , 即有

$$\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*) = \mathbf{b} + \delta\mathbf{b}.$$

注意到  $\mathbf{Ax}^* = \mathbf{b}$ , 则得

$$\mathbf{A}\delta\mathbf{x}^* = \delta\mathbf{b},$$

即

$$\delta\mathbf{x}^* = \mathbf{A}^{-1}\delta\mathbf{b}.$$

两边取范数并由 矩阵范数性质 得

$$\|\delta\mathbf{x}^*\| \leq \|\mathbf{A}^{-1}\| \|\delta\mathbf{b}\|.$$

另一方面, 由方程  $\mathbf{A}\mathbf{x}^* = \mathbf{b}$  可得

$$\|\mathbf{b}\| \leq \|\mathbf{A}\| \|\mathbf{x}^*\|.$$

从而有

$$\frac{\|\delta\mathbf{x}^*\|}{\|\mathbf{x}^*\|} \leq \|\mathbf{A}^{-1}\| \|\mathbf{A}\| \frac{\|\delta\mathbf{b}\|}{\|\mathbf{b}\|}. \quad (2.1)$$

(2) 设  $\mathbf{A}$  有微小变化  $\delta\mathbf{A}$ , 解变为  $\mathbf{x}^* + \delta\mathbf{x}^*$ . 即

$$(\mathbf{A} + \delta\mathbf{A})(\mathbf{x}^* + \delta\mathbf{x}^*) = \mathbf{b}.$$

利用方程  $\mathbf{A}\mathbf{x}^* = \mathbf{b}$  得

$$\delta\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*) + \mathbf{A}\delta\mathbf{x}^* = 0,$$

即

$$\delta\mathbf{x}^* = -\mathbf{A}^{-1}\delta\mathbf{A}(\mathbf{x}^* + \delta\mathbf{x}^*).$$

两边取范数得

$$\frac{\|\delta\mathbf{x}^*\|}{\|\mathbf{x}^* + \delta\mathbf{x}^*\|} \leq \|\mathbf{A}\| \|\mathbf{A}^{-1}\| \frac{\|\delta\mathbf{A}\|}{\|\mathbf{A}\|}. \quad (2.2)$$

**定义 2.10** 设  $\mathbf{A}$  为非奇异矩阵, 称  $\|\mathbf{A}\| \|\mathbf{A}^{-1}\|$  为矩阵  $\mathbf{A}$  的条件数, 记为

$$\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|.$$

## 常用的条件数

$$(1) \operatorname{cond}(\mathbf{A})_{\infty} = \|\mathbf{A}\|_{\infty} \|\mathbf{A}^{-1}\|_{\infty}.$$

$$(2) \operatorname{cond}(\mathbf{A})_2 = \|\mathbf{A}\|_2 \|\mathbf{A}^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}{\lambda_{\min}(\mathbf{A}^T \mathbf{A})}}.$$

当  $\mathbf{A}$  对称正定时,  $\operatorname{cond}(\mathbf{A})_2 = \frac{\lambda_1}{\lambda_n}$

其中,  $\lambda_{\max}(\mathbf{A}^T \mathbf{A})$  和  $\lambda_{\min}(\mathbf{A}^T \mathbf{A})$  分别为  $\mathbf{A}^T \mathbf{A}$  的最大特征值和最小特征值,  $\lambda_1$  和  $\lambda_n$  分别为  $\mathbf{A}$  的最大特征值和最小特征值.

**定义 2.11** 对于方程组  $\mathbf{A}\mathbf{x} = \mathbf{b}$ , 其中  $\mathbf{A}$  非奇异. 如果  $\mathbf{A}$  的条件数很大, 则称该方程组为病态 (坏条件) 方程组; 如果  $\mathbf{A}$  的条件数比较小, 则称该方程组为良态 (好条件) 方程组.

可以计算例 (2.1) 中矩阵的条件数  $\operatorname{cond}(\mathbf{A})_{\infty} = 2$ , 故例 (2.1) 中的方程组是良态的. 而例 (2.2) 中矩阵的条件数  $\operatorname{cond}(\mathbf{A})_{\infty} = 22002$ , 故例 (2.1) 中的方程组是病态的.

在实际中, 由于计算  $\mathbf{A}^{-1}$  较困难, 所以  $\operatorname{cond}(\mathbf{A})$  不容易计算. 但可以通过下面情形来判断病态矩阵:

(1) 用列主元 Gauss 消去法时出现绝对值很小的主元.



(2) 系数矩阵某些行 (列) 近似线性相关.

(3) 系数矩阵元素间数量级相差很大, 且没有一定规律.

对于病态方程组, 一般可以采用

(1) 双精度计算, 减少舍入误差;

(2) 对方程组进行预处理. 即选择非奇异矩阵  $D, C$ , 将方程组  $Ax = b$  化为等价的方程组  $DAC[C^{-1}x] = Db$ , 使  $DAC$  的条件数比较小.

(3) 正则化方法.

## 2.4 方程组近似解可靠性的判别

设  $\tilde{x}$  为方程组  $Ax = b$  的近似解, 记  $r = b - A\tilde{x}$ , 若  $r = 0$ , 则  $\tilde{x}$  为精确解. 一般  $r \neq 0$ .

**问题** 能否根据  $\|r\|$  的大小来判断近似解  $\tilde{x}$  的精确程度?

**定理 2.8** 设  $\tilde{x}$  是方程组  $Ax = b$  的一个近似解,  $x^*$  为精确解,  $r = b - A\tilde{x}$ . 则

$$\frac{\|x^* - \tilde{x}\|}{\|x^*\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|}.$$

# 3 线性方程组的迭代法

## 3.1 迭代格式的构造

设  $A$  非奇异,  $b \neq 0$ . 考虑方程组  $Ax = b$ , 设其解为  $x^*$ . 将方程组改写为等价的方程

$$x = Bx + f$$

这里  $B$  为  $n$  阶方阵,  $f \in \mathbf{R}^n$ . 任取一个向量  $x^{(0)} \in \mathbf{R}^n$ , 产生迭代

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, 2, \dots \quad (3.1)$$

上式产生一个向量序列  $\{x^{(k)}\}_{k=0}^{\infty}$ . 若它收敛于  $\bar{x}$ , 即

$$\lim_{k \rightarrow \infty} x^{(k)} = \bar{x},$$

(3.1) 两边取极限得  $\bar{x} = B\bar{x} + f$ , 它等价于  $A\bar{x} = b$ . 故  $\bar{x}$  是原方程组的解, 即  $x^* = \bar{x}$ .

(3.1) 称为迭代格式,  $B$  为迭代矩阵, 称  $x^{(k)}$  为第  $k$  次迭代近似解,  $e^{(k)} = x^* - x^{(k)}$  为第  $k$  次迭代误差. 如果迭代格式 (3.1) 对任意初始向量  $x^{(0)}$  产生的迭代序列  $\{x^{(k)}\}_{k=0}^{\infty}$  均收敛, 称该迭代收敛.

问题

(1) 怎样构造迭代格式? (2) 迭代何时收敛?

## 3.2 三个常用的迭代格式

将线性方程组  $\mathbf{Ax} = \mathbf{b}$  写为分量形式

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \cdots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 + \cdots + a_{2n}x_n = b_2, \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \cdots + a_{3n}x_n = b_3, \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \cdots + a_{nn}x_n = b_n. \end{cases}$$

假设  $a_{ii} \neq 0$  ( $i = 1, 2, \dots, n$ ).

### (1) Jacobi 迭代格式

在上述方程组中第  $i$  个方程求出  $x_i$  得

$$\begin{cases} x_1 = (b_1 - a_{12}x_2 - a_{13}x_3 - \cdots - a_{1n}x_n)/a_{11}, \\ x_2 = (b_2 - a_{21}x_1 - a_{23}x_3 - \cdots - a_{2n}x_n)/a_{22}, \\ x_3 = (b_3 - a_{31}x_1 - a_{32}x_2 - \cdots - a_{3n}x_n)/a_{33}, \\ \vdots \\ x_n = (b_n - a_{n1}x_1 - a_{n2}x_2 - \cdots - a_{n,n-1}x_{n-1})/a_{nn}. \end{cases}$$

从而产生下面的 Jacobi 迭代格式

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}, \\ x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k)} - a_{32}x_2^{(k)} - \cdots - a_{3n}x_n^{(k)})/a_{33}, \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k)} - a_{n2}x_2^{(k)} - \cdots - a_{n,n-1}x_{n-1}^{(k)})/a_{nn}, \end{cases}$$
$$k = 0, 1, \cdots .$$

下面将 Jacobi 迭代用矩阵和向量表示. 记

$$\mathbf{L} = \begin{bmatrix} 0 & & & & \\ a_{21} & 0 & & & \\ a_{31} & a_{32} & 0 & & \\ \vdots & \vdots & \vdots & \ddots & \\ a_{n-1,1} & a_{n-1,2} & a_{n-1,3} & \cdots & 0 \\ a_{n1} & a_{n2} & a_{n3} & \cdots & a_{n,n-1} & 0 \end{bmatrix},$$

$$\mathbf{D} = \begin{bmatrix} a_{11} & & & & \\ & a_{22} & & & \\ & & a_{33} & & \\ & & & \ddots & \\ & & & & a_{nn} \end{bmatrix}, \quad \mathbf{U} = \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ & 0 & a_{23} & \cdots & a_{2n} \\ & & \ddots & \ddots & \vdots \\ & & & 0 & a_{n,n-1} \\ & & & & 0 \end{bmatrix},$$

则

$$\begin{aligned} \mathbf{A} &= \mathbf{L} + \mathbf{D} + \mathbf{U} \implies \\ \mathbf{A}\mathbf{x} &= \mathbf{b} \iff (\mathbf{L} + \mathbf{D} + \mathbf{U})\mathbf{x} = \mathbf{b} \\ \implies \mathbf{D}\mathbf{x} &= -(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{b} \\ \implies \mathbf{x} &= -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{x} + \mathbf{D}^{-1}\mathbf{b}. \end{aligned}$$

Jacobi 迭代格式:

$$\mathbf{x}^{(k+1)} = \mathbf{J}\mathbf{x}^{(k)} + \mathbf{f}_J, \quad k = 0, 1, \dots,$$

其中

$$\mathbf{J} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad \mathbf{f}_J = \mathbf{D}^{-1}\mathbf{b}.$$

## (2) Gauss-Seidel 迭代格式

在 Jacobi 迭代中将已经求出的分量直接参加下一个分量的计算, 得到下面的 Gauss-Seidel 迭代格式:

$$\begin{cases} x_1^{(k+1)} = (b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \cdots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \cdots - a_{2n}x_n^{(k)})/a_{22}, \\ x_3^{(k+1)} = (b_3 - a_{31}x_1^{(k+1)} - a_{32}x_2^{(k+1)} - a_{34}x_4^{(k)} - \cdots - a_{3n}x_n^{(k)})/a_{33}, \\ \vdots \\ x_n^{(k+1)} = (b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \cdots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn}, \end{cases}$$
$$k = 0, 1, \dots$$

用矩阵表示为:

$$\begin{aligned} \mathbf{x}^{(k+1)} &= \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}\mathbf{x}^{(k+1)} - \mathbf{U}\mathbf{x}^{(k)}), \\ \implies (\mathbf{D} + \mathbf{L})\mathbf{x}^{(k+1)} &= \mathbf{b} - \mathbf{U}\mathbf{x}^{(k)}. \end{aligned}$$

Gauss-Seidel 迭代格式:

$$\mathbf{x}^{(k+1)} = \mathbf{G}\mathbf{x}^{(k)} + \mathbf{f}_G, \quad k = 0, 1, \dots,$$

其中

$$\mathbf{G} = -(\mathbf{D} + \mathbf{L})^{-1}\mathbf{U}, \quad \mathbf{f}_G = (\mathbf{D} + \mathbf{L})^{-1}\mathbf{b}.$$

### (3) **SOR**(逐次超松弛) 迭代格式

已知  $\mathbf{x}^{(k)} = (x_1^{(k)}, x_2^{(k)}, \dots, x_n^{(k)})^T$ , 将 Gauss-Seidel 迭代中的  $\mathbf{x}^{(k+1)}$  与  $\mathbf{x}^{(k)}$  加权平均, 得到 **SOR** 迭代:

$$\begin{cases} x_1^{(k+1)} = (1 - \omega)x_1^{(k)} + \omega(b_1 - a_{12}x_2^{(k)} - a_{13}x_3^{(k)} - \dots - a_{1n}x_n^{(k)})/a_{11}, \\ x_2^{(k+1)} = (1 - \omega)x_2^{(k)} + \omega(b_2 - a_{21}x_1^{(k+1)} - a_{23}x_3^{(k)} - \dots - a_{2n}x_n^{(k)})/a_{22}, \\ \vdots \\ x_n^{(k+1)} = (1 - \omega)x_n^{(k)} + \omega(b_n - a_{n1}x_1^{(k+1)} - a_{n2}x_2^{(k+1)} - \dots - a_{n,n-1}x_{n-1}^{(k+1)})/a_{nn}, \end{cases}$$

$$k = 0, 1, \dots,$$

其中  $\omega$  称为松弛因子. 当  $\omega = 1$ , 上式成为 Gauss-Seidel 迭代.  
将 **SOR** 迭代用矩阵表示:

$$\begin{aligned} x^{(k+1)} &= (1 - \omega)x^{(k)} + \omega \mathbf{D}^{-1}(\mathbf{b} - \mathbf{L}x^{(k+1)} - \mathbf{U}x^{(k)}), \implies \\ \mathbf{D}x^{(k)} &= (1 - \omega)\mathbf{D}x^{(k)} + \omega(\mathbf{b} - \mathbf{L}x^{(k+1)} - \mathbf{U}x^{(k)}), \implies \\ (\mathbf{D} + \omega\mathbf{L})x^{(k+1)} &= [(1 - \omega)\mathbf{D} - \omega\mathbf{U}]x^{(k)} + \omega\mathbf{b}, \implies \\ x^{(k+1)} &= \mathbf{S}_\omega x^{(k)} + \mathbf{f}_\omega, \end{aligned}$$

其中

$$\mathbf{S}_\omega = (\mathbf{D} + \omega\mathbf{L})^{-1}[(1 - \omega)\mathbf{D} - \omega\mathbf{U}], \quad \mathbf{f}_\omega = \omega(\mathbf{D} + \omega\mathbf{L})^{-1}\mathbf{b}.$$

### 3.3 迭代格式的收敛性

#### (1) 迭代法基本定理

**定理 3.1** 迭代格式  $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$  ( $k = 0, 1, 2, \dots$ ) 收敛  $\iff \rho(\mathbf{B}) < 1$ .

**定理 3.2** 若迭代矩阵  $\|\mathbf{B}\| < 1$ , 则迭代  $\mathbf{x}^{(k+1)} = \mathbf{B}\mathbf{x}^{(k)} + \mathbf{f}$  收敛.

我们还可以证明: 若  $\|\mathbf{B}\| < 1$ , 则对  $k = 1, 2, 3, \dots$  有

$$\begin{aligned}\|\mathbf{x}^* - \mathbf{x}^{(k)}\| &\leq \frac{\|\mathbf{B}\|}{1 - \|\mathbf{B}\|} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|, \\ \|\mathbf{x}^* - \mathbf{x}^{(k)}\| &\leq \frac{\|\mathbf{B}\|^k}{1 - \|\mathbf{B}\|} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|.\end{aligned}$$

#### (2) Jacobi 迭代和 Gauss-Seidel 迭代的收敛性

由定理 3.1, Jacobi 迭代收敛  $\iff \rho(\mathbf{J}) < 1$ .  $\mathbf{J}$  的特征方程为

$$\begin{aligned}|\lambda \mathbf{I} - \mathbf{J}| &= |\lambda \mathbf{I} + \mathbf{D}^{-1}(\tilde{\mathbf{L}} + \mathbf{U})| = |\mathbf{D}^{-1}(\lambda \mathbf{D} + \mathbf{L} + \mathbf{U})| = 0. \\ \iff |\lambda \mathbf{D} + \mathbf{L} + \mathbf{U}| &= 0.\end{aligned}$$



### 例 3.1 给定线性方程组

$$\begin{bmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 3 \end{bmatrix}.$$

- (1) 写出 Jacobi 迭代格式.
- (2) 分析 Jacobi 迭代格式的收敛性.

解 (1) Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k)} - x_2^{(k)})/(-5). \end{cases}$$

(2) Jacobi 迭代矩阵  $\mathbf{J}$  的特征方程为

$$\begin{vmatrix} 8\lambda & -1 & 1 \\ 2 & 10\lambda & -1 \\ 1 & 1 & -5\lambda \end{vmatrix} = 0,$$

展开得

$$400\lambda^3 + 12\lambda - 3 = 0,$$

用 Newton 迭代法求得一个实根为  $\lambda_1 = 0.146084$ . 记另两根为  $\lambda_2, \lambda_3$ , 通过待定系数可得

$$(\lambda - \lambda_1)(400\lambda^3 + b\lambda + c) = 0,$$

其中

$$b = \frac{1}{400\lambda_1}, \quad c = \frac{3}{\lambda_1}.$$

易知  $\lambda_1, \lambda_2$  为共轭复根, 且有

$$|\lambda_2\lambda_3| = \frac{3}{400\lambda_1},$$

$$|\lambda_1| = |\lambda_2| = \sqrt{\frac{3}{400\lambda_1}} = 0.226584,$$

所以

$$\rho(\mathbf{J}) = \max_{i=1,2,3} \{|\lambda_i|\} = 0.226584 < 1,$$

Jacobi 迭代收敛.

同样由定理 3.1, Gauss-Seidel 迭代收敛  $\iff \rho(\mathbf{G}) < 1$ .  $\mathbf{G}$  的特征方程为

$$\begin{aligned} |\lambda \mathbf{I} - \mathbf{G}| &= |\lambda \mathbf{I} + (\mathbf{D} + \mathbf{L})^{-1} \mathbf{U}| \\ &= |(\mathbf{D} + \mathbf{L})^{-1} (\lambda (\mathbf{D} + \mathbf{L}) + \mathbf{U})| = 0. \\ \iff |(\lambda (\mathbf{D} + \mathbf{L}) + \mathbf{U})| &= 0. \end{aligned}$$

### 例 3.2 给定线性方程组

$$\begin{bmatrix} 8 & -1 & 1 \\ 2 & 10 & -1 \\ 1 & 1 & -5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 3 \end{bmatrix}.$$

(1) 写出 Gauss-Seidel 迭代格式.

(2) 分析 Gauss-Seidel 迭代格式的收敛性.

解 (1) Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (1 + x_2^{(k)} - x_3^{(k)})/8, \\ x_2^{(k+1)} = (4 - 2x_1^{(k+1)} + x_3^{(k)})/10, \\ x_3^{(k+1)} = (3 - x_1^{(k+1)} - x_2^{(k+1)})/(-5). \end{cases}$$

(2) Gauss-Seidel 迭代矩阵  $\mathbf{G}$  的特征方程为

$$\begin{vmatrix} 8\lambda & -1 & 1 \\ 2\lambda & 10\lambda & -1 \\ \lambda & \lambda & -5\lambda \end{vmatrix} = 0,$$

展开得

$$\lambda(400\lambda^2 + 10\lambda - 1),$$

求得

$$\lambda_1 = 0, \quad \lambda_2 = \frac{-1 + \sqrt{17}}{80}, \quad \lambda_3 = \frac{-1 - \sqrt{17}}{80},$$

$$\rho(\mathbf{G}) = \max_{i=1,2,3} \{|\lambda_i|\} = 0.0640388 < 1,$$

Gauss-Seidel 迭代收敛.

定义 3.1 设

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

如果

$$|a_{ii}| > \sum_{\substack{j=1 \\ i \neq j}}^n |a_{ij}|, \quad i = 1, 2, \cdots, n$$

则称  $\mathbf{A}$  按行严格对角占优；如果

$$|a_{jj}| > \sum_{\substack{i=1 \\ j \neq i}}^n |a_{ij}|, \quad j = 1, 2, \cdots, n$$

则称  $\mathbf{A}$  按列严格对角占优。按行严格对角占优或按列严格对角占优统称为严格对角占优。

引理 3.1 设  $A$  是严格对角占优矩阵, 则  $|A| \neq 0$ .

证 这里仅证  $\mathbf{A}$  是按行严格对角占优的情况. 用反证法.

设  $|\mathbf{A}| \neq 0$ , 则齐次方程组  $\mathbf{A}\mathbf{x} = \mathbf{0}$  有非零解  $\mathbf{x}^* = (x_1^*, x_2^*, \dots, x_n^*)^T$ .

设  $\|\mathbf{x}^*\|_\infty = |x_k^*| \neq 0$ . 由第  $k$  个方程

$$a_{kk}x_k^* + \sum_{j=1, j \neq k}^n a_{kj}x_j^* = 0$$

可得

$$\begin{aligned} |a_{kk}| \cdot |x_k^*| &= \left| \sum_{j=1, j \neq k}^n a_{kj}x_j^* \right| \leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_j^*| \\ &\leq \sum_{j=1, j \neq k}^n |a_{kj}| \cdot |x_k^*| \end{aligned}$$

两边约去  $|x_k^*|$ , 得

$$|a_{kk}| \leq \sum_{j=1, j \neq k}^n |a_{kj}|$$

与按行严格对角占优矛盾. 因而  $|\mathbf{A}| \neq 0$ .



**定理 3.3**      给定线性方程组  $Ax = b$ , 如果  $A$  是严格对角占优矩阵, 则 Jacobi 迭代格式收敛.

证明 记

$$\mathbf{B}(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则 Jacobi 迭代矩阵  $\mathbf{J}$  的特征方程为  $|\mathbf{B}(\lambda)| = 0$ . 设  $\mathbf{A}$  是按行严格对角占优的, 则当  $|\lambda| \geq 1$  时, 有

$$|\lambda a_{ii}| \geq |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}| \quad (i = 1, 2, \cdots, n)$$

即  $\mathbf{B}(\lambda)$  是严格按行对角占优的。由上面的一个引理可知, 当  $|\lambda| \geq 1$  时,  $|\mathbf{B}(\lambda)| \neq 0$ . 换句话说, 方程  $|\mathbf{B}(\lambda)| = 0$  的  $n$  个根  $\lambda_1, \lambda_2, \cdots, \lambda_n$  都应满足  $|\lambda_i| < 1, i = 1, 2, \cdots, n$ . 于是  $\rho(\mathbf{J}) < 1$ . 同样可证当  $\mathbf{A}$  按列严格对角占优的情况。因而 Jacobi 迭代格式收敛。

**定理 3.4**      给定线性方程组  $Ax = b$ , 如果  $A$  是严格对角占优矩阵, 则 Gauss-Seidel 迭代格式收敛.

证 记

$$\mathbf{C}(\lambda) = \begin{pmatrix} \lambda a_{11} & a_{12} & \cdots & a_{1n} \\ \lambda a_{21} & \lambda a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ \lambda a_{n1} & \lambda a_{n2} & \cdots & \lambda a_{nn} \end{pmatrix}$$

则 Gauss-Seidel 迭代矩阵  $\mathbf{G}$  的特征方程为  $|\mathbf{C}(\lambda)| = 0$ . 设  $\mathbf{A}$  是按行严格对角占优的, 则当  $|\lambda| \geq 1$  时, 有

$$\begin{aligned} |\lambda a_{ii}| &= |\lambda| |a_{ii}| > |\lambda| \sum_{j=1, j \neq i}^n |a_{ij}| \\ &\geq |\lambda| \sum_{j=1}^{i-1} |a_{ij}| + \sum_{j=i+1}^n |a_{ij}| \quad i = 1, 2, \cdots, n \end{aligned}$$

即  $\mathbf{C}(\lambda)$  是严格按行对角占优的。由上面的一个引理可知, 当  $|\lambda| \geq 1$  时,  $|\mathbf{C}(\lambda)| \neq 0$ . 换句话说, 方程  $|\mathbf{C}(\lambda)| = 0$  的  $n$  个根  $\lambda_1, \lambda_2, \cdots, \lambda_n$  都应满足  $|\lambda_i| < 1, i = 1, 2, \cdots, n$ . 于是  $\rho(\mathbf{G}) < 1$ . 同样可证当  $\mathbf{A}$  按列严格对角占优的情况。因而 Gauss-Seidel 迭代格式收敛。

注 3.1 由定理3.3 和定理3.4 知, 例3.1 和例3.2 中的系数矩阵严格对角占优, 故 Jacobi 迭代和 Gauss-Seidel 迭代均收敛.

(3) SOR 迭代的收敛性  
SOR 迭代的迭代矩阵为

$$S_\omega = (\mathbf{D} + \omega \mathbf{L})^{-1}[(1 - \omega)\mathbf{D} - \omega \mathbf{U}],$$

由定理 3.1, SOR 迭代收敛  $\iff \rho(S_\omega) < 1$ .

定理 3.5      SOR 迭代收敛的必要条件是  $0 < \omega < 2$ .

证 设  $S_\omega$  的特征值为  $\lambda_1, \lambda_2, \dots, \lambda_n$ , 则由线性代数知

$$|\det(S_\omega)| = |\lambda_1 \lambda_2 \cdots \lambda_n| \leq \rho(S_\omega)^n.$$

另一方面, 由定理 3.1, 若 SOR 收敛, 则  $\rho(S_\omega) < 1$ , 从而有  $|\det(S_\omega)| < 1$ . 而行列式

$$\begin{aligned} \det(S_\omega) &= \det[(\mathbf{D} + \omega \mathbf{L})^{-1}] \det[(1 - \omega) \mathbf{D} - \omega \mathbf{U}] \\ &= \left( \prod_{i=1}^n a_{ii} \right)^{-1} \prod_{i=1}^n [(1 - \omega) a_{ii}] \\ &= (1 - \omega)^n. \end{aligned}$$

从而有

$$|(1 - \omega)^n| < 1, \quad \implies 0 < \omega < 2.$$

**定理 3.6** 给定线性方程组  $Ax = b$ . 如果  $A$  对称正定, 且  $0 < \omega < 2$ , 则 SOR 迭代收敛.

**注 3.2** 如果  $A$  对称正定, 则 Gauss-Seidel 迭代收敛.



### 例 3.3 给定线性方程组

$$\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

(a) 分别写出解该方程组的 Jacobi 迭代和 Gauss-Seidel 迭代格式.

(b) 分析这两种迭代格式的收敛性.

解

(a) Jacobi 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (-x_2^{(k)} - x_3^{(k)} + 1)/2, \\ x_2^{(k+1)} = (-x_1^{(k)} - x_3^{(k)} + 2)/2, \\ x_3^{(k+1)} = (-x_1^{(k)} - x_2^{(k)} + 3)/2. \end{cases} \quad k = 0, 1, \dots$$

Gauss-Seidel 迭代格式为

$$\begin{cases} x_1^{(k+1)} = (-x_2^{(k)} - x_3^{(k)} + 1)/2, \\ x_2^{(k+1)} = (-x_1^{(k+1)} - x_3^{(k)} + 2)/2, \\ x_3^{(k+1)} = (-x_1^{(k+1)} - x_2^{(k+1)} + 3)/2. \end{cases} \quad k = 0, 1, \dots$$

(b) Jacobi 迭代矩阵  $\mathbf{J}$  的特征方程为

$$\begin{vmatrix} 2\lambda & 1 & 1 \\ 1 & 2\lambda & 1 \\ 1 & 1 & 2\lambda \end{vmatrix} = 0,$$

展开得

$$4\lambda^3 - 3\lambda + 1 = 0,$$

即有

$$(2\lambda - 1)^2(\lambda + 1) = 0,$$

求得

$$\lambda_{1,2} = \frac{1}{2}, \quad \lambda_3 = -1,$$

所以  $\rho(\mathbf{J}) = 1$ , 故 Jacobi 迭代发散.

Gauss-Seidel 迭代矩阵  $\mathbf{G}$  的特征方程是

$$\begin{vmatrix} 2\lambda & 1 & 1 \\ \lambda & 2\lambda & 1 \\ \lambda & \lambda & 2\lambda \end{vmatrix} = 0,$$

展开得

$$\lambda(8\lambda^2 - 2\lambda + 1) = 0,$$

求得

$$\lambda_1 = 0, \quad \lambda_{2,3} = \frac{1 \pm \sqrt{7}\mathbf{i}}{8},$$

所以  $\rho(\mathbf{G}) = \frac{\sqrt{2}}{4} < 1$ , 故 Gauss-Seidel 迭代收敛.

例 3.4 给定线性方程组  $\mathbf{Ax} = \mathbf{b}$ ,  $\mathbf{A}$  为  $n$  阶非奇异矩阵. 构造迭代

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega(\mathbf{b} - \mathbf{Ax}^{(k)}), \quad (k = 0, 1, 2, \dots)$$

其中  $\omega \neq 0$  为常数.

(a) 证明: 如果迭代收敛, 则迭代序列  $\{\mathbf{x}^{(k)}\}_{k=0}^{\infty}$  收敛于方程  $\mathbf{Ax} = \mathbf{b}$  的解.

(b) 设  $\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix}$ , 则  $\omega$  取何值时迭代收敛?

解

(a) 证 设  $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$ . 在迭代格式两边取极限

$$\lim_{k \rightarrow \infty} \mathbf{x}^{(k+1)} = \lim_{k \rightarrow \infty} [\mathbf{x}^{(k)} + \omega(\mathbf{b} - \mathbf{Ax}^{(k)})].$$

得  $\mathbf{x}^* = \mathbf{x}^* + \omega(\mathbf{b} - \mathbf{Ax}^*)$ . 因为  $\omega \neq 0$ , 所以  $\mathbf{Ax}^* = \mathbf{b}$ , 即  $\mathbf{x}^*$  是方程  $\mathbf{Ax} = \mathbf{b}$  的解.

(b) 迭代格式的迭代矩阵为  $\mathbf{I} - \omega\mathbf{A}$ , 迭代收敛  $\iff \rho(\mathbf{I} -$

$\omega \mathbf{A}) < 1$ . 矩阵  $\mathbf{I} - \omega \mathbf{A}$  的特征方程为

$$|\lambda \mathbf{I} - \mathbf{I} - \omega \mathbf{A}| = \begin{vmatrix} (\lambda - 1 + 2\omega) & \omega & \omega \\ \omega & (\lambda - 1 + 2\omega) & \omega \\ \omega & \omega & (\lambda - 1 + 2\omega) \end{vmatrix} = 0,$$

$$\text{记 } \mu = (\lambda - 1 + 2\omega), \implies \mu^3 - 3\omega^2\mu + 2\omega^3 = 0,$$

$$\implies (\mu - \omega)^2(\mu + 2\omega) = 0.$$

$$\implies \mu = \omega \text{ 或 } \mu = -2\omega, \implies \lambda = 1 - \omega \text{ 或 } \lambda = 1 - 4\omega.$$

$$\begin{cases} |1 - \omega| < 1 \\ |1 - 4\omega| < 1 \end{cases} \implies 0 < \omega < \frac{1}{2}.$$

## 4 幂法与反幂法

幂法和反幂法是迭代法. 幂法用于求矩阵按模最大的特征值和对应的特征向量. 当特征值非零时, 反幂法用于求按模最小的特征值和对应的特征向量.

### 4.1 求主特征值的幂法

设  $\mathbf{A} = (a_{ij})_{n \times n}$  是  $n$  阶方阵, 它有  $n$  个线性无关的特征向量  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ , 对应的特征值为  $\lambda_j (j = 1, 2, \dots, n)$ , 按模的大小排列

$$|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|,$$

其中  $\lambda_1$  是主特征值. 给定初值非零向量  $\mathbf{v}_0$ , 构造迭代

$$\mathbf{v}_k = \mathbf{A}\mathbf{v}_{k-1}, \quad k = 1, 2, \dots.$$

$\mathbf{v}_0$  可由  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$  线性表示, 设表示为

$$\mathbf{v}_0 = \sum_{i=1}^n a_i \mathbf{x}_i,$$

且  $a_1 \neq 0$ . 因此有

$$\mathbf{v}_k = \mathbf{A}\mathbf{v}_{k-1} = \mathbf{A}^k \mathbf{v}_0 = \mathbf{A}^k \sum_{i=1}^n a_i \mathbf{x}_i = \sum_{i=1}^n a_i \lambda_i^k \mathbf{x}_i, \quad k = 1, 2, \dots$$

(1) 特征值满足  $|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$ . 则

$$\begin{aligned} \mathbf{v}_k &= \lambda_1^k \left[ a_1 \mathbf{x}_1 + a_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k \mathbf{x}_2 + \dots + a_n \left( \frac{\lambda_n}{\lambda_1} \right)^k \mathbf{x}_n \right] \\ \mathbf{v}_{k+1} &= \lambda_1^{k+1} \left[ a_1 \mathbf{x}_1 + a_2 \left( \frac{\lambda_2}{\lambda_1} \right)^{k+1} \mathbf{x}_2 + \dots + a_n \left( \frac{\lambda_n}{\lambda_1} \right)^{k+1} \mathbf{x}_n \right] \end{aligned}$$

因为

$$|\lambda_1| > |\lambda_i| \quad i = 2, 3, \dots, n,$$

故

$$\lim_{k \rightarrow \infty} \left( \frac{\lambda_i}{\lambda_1} \right)^k = 0, \quad i = 2, 3, \dots, n.$$

从而当  $k$  充分大, 有

$$\mathbf{v}_k \approx a_1 \lambda_1^k \mathbf{x}_1, \quad \mathbf{v}_{k+1} \approx a_1 \lambda_1^{k+1} \mathbf{x}_1 \approx \lambda_1 \mathbf{v}_k. \quad (4.1)$$

由上式知  $\mathbf{v}_{k+1} = \mathbf{A}\mathbf{v}_k \approx \lambda_1 \mathbf{v}_k$ . 该式说明  $\mathbf{v}_k$  是  $\lambda_1$  对应的近似特征向量,  $\mathbf{v}_k$  和  $\mathbf{v}_{k+1}$  近似线性相关. 所以

$$\lambda_1 = \lim_{k \rightarrow \infty} \frac{(\mathbf{v}_{k+1})_i}{(\mathbf{v}_k)_i},$$

其中  $(\mathbf{v}_k)_i$  表示  $\mathbf{v}_k$  的第  $i$  个分量. 实际计算时, 为了避免  $\mathbf{v}_k$  的分量产生溢出, 可以采用“归一化”, 具体将算法改为:

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0, \\ \mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1}, \\ m_k = \max(\mathbf{v}_k), \\ \mathbf{u}_k = \mathbf{v}_k / m_k, \end{cases} \quad k = 1, 2, \dots, \quad (4.2)$$

其中  $m_k = \max(\mathbf{v}_k)$  表示  $\mathbf{v}_k$  中 (首次出现的) 绝对值最大的分量.



定理 4.1 设  $|\lambda_1| > |\lambda_2| \geq \cdots \geq |\lambda_n|$ , 则由算法 (4.2) 产生的序列  $\{\mathbf{u}_k\}$  和  $\{m_k\}$  均收敛, 且

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}, \quad \lim_{k \rightarrow \infty} m_k = \lambda_1.$$

证

$$\mathbf{u}_k = \frac{1}{m_k} \mathbf{v}_k = \frac{1}{m_k} \mathbf{A} \mathbf{u}_{k-1}, \quad k = 1, 2, \dots,$$

利用上式递推得

$$\begin{aligned} \mathbf{u}_k &= \frac{1}{m_k} \mathbf{A} \left( \frac{1}{m_{k-1}} \mathbf{A} \mathbf{u}_{k-2} \right) \\ &= \frac{1}{m_k m_{k-1}} \mathbf{A}^2 \mathbf{u}_{k-2} \\ &= \dots \\ &= \frac{1}{m_k m_{k-1} \cdots m_1} \mathbf{A}^k \mathbf{u}_0. \end{aligned}$$

由  $\mathbf{u}_k$  的归一化,  $m_k m_{k-1} \cdots m_1 = \frac{\max(\mathbf{A}^k \mathbf{u}_0)}{\max(\mathbf{u}_k)} = \max(\mathbf{A}^k \mathbf{u}_0),$

$$\mathbf{u}_k = \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)}$$

$$\begin{aligned}
& \lambda_1^k \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right) \\
= & \frac{\lambda_1^k \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left( \lambda_1^k \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right) \right)} \\
= & \frac{a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i}{\max \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}.
\end{aligned}$$

从而

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_1}{\max(\mathbf{x}_1)}.$$

同样

$$\mathbf{v}_k = \mathbf{A} \mathbf{u}_{k-1} = \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^{k-1} \mathbf{u}_0)}$$

$$= \frac{\lambda_1 \max \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^k \mathbf{x}_i \right)}{\max \left( a_1 \mathbf{x}_1 + \sum_{i=2}^n a_i \left( \frac{\lambda_i}{\lambda_1} \right)^{k-1} \mathbf{x}_i \right)}.$$

因此

$$\lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

从以上分析知幂法的收敛速度与  $\left| \frac{\lambda_2}{\lambda_1} \right|$  有关, 称比值  $\left| \frac{\lambda_2}{\lambda_1} \right|$  为幂法的收敛速率.

### 例 4.1 用幂法计算矩阵

$$\mathbf{A} = \begin{bmatrix} 2 & 3 & 2 \\ 10 & 3 & 4 \\ 3 & 6 & 1 \end{bmatrix}$$

的主特征值及对应的特征向量.

解 取  $\mathbf{u}_0 = (0, 0, 1)^T$ , 由 (4.2) 构造迭代

$$\mathbf{u}_0 = \mathbf{v}_0,$$

$$\mathbf{v}_k = \mathbf{A}\mathbf{u}_{k-1},$$

$$m_k = \max(\mathbf{v}_k),$$

$$\mathbf{u}_k = \mathbf{v}_k/m_k, \quad k = 1, 2, \dots$$

计算结果见表6.1.

表 6.1 幂法求主特征值

$k$	$\mathbf{u}_k^T$	$m_k$
0	(0, 0, 1)	1
1	(0.5, 1.0, 0.25)	4
2	(0.5, 1.0, 0.8611)	9
3	(0.5, 1.0, 0.7306)	11.4400
4	(0.5, 1.0, 0.7535)	10.9224
5	(0.5, 1.0, 0.7493)	11.0140
6	(0.5, 1.0, 0.7501)	10.9927
7	(0.5, 1.0, 0.7500)	11.0004
8	(0.5, 1.0, 0.7500)	11.0000

(2) 当  $|\lambda_1| = |\lambda_2|$ , 且  $|\lambda_2| > |\lambda_3|$  时.

(a)  $\lambda_1 = \lambda_2$ .

$$\begin{aligned}\mathbf{u}_k &= \frac{\mathbf{A}^k \mathbf{u}_0}{\max(\mathbf{A}^k \mathbf{u}_0)} \\ &= \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i}{\max\left(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2 + \sum_{i=3}^n a_i \left(\frac{\lambda_i}{\lambda_1}\right)^k \mathbf{x}_i\right)}\end{aligned}$$

因此

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2}{\max(a_1 \mathbf{x}_1 + a_2 \mathbf{x}_2)}.$$

$$\lim_{k \rightarrow \infty} m_k = \lim_{k \rightarrow \infty} \max(\mathbf{v}_k) = \lambda_1.$$

(b)  $\lambda_1 = -\lambda_2$

(c)  $\lambda_1 = \bar{\lambda}_2$

## 4.2 反幂法

当  $\mathbf{A}$  非奇异时,  $\mathbf{A}$  的特征值非零.  $\mathbf{A}^{-1}$  的按模最大特征值就是  $\mathbf{A}$  的按模最小的特征值. 因此用幂法可以求  $\mathbf{A}^{-1}$  的按模最大的特征值即  $\mathbf{A}$  的按模最小的特征值, 这就是反幂法. 算法如下:

$$\begin{cases} \mathbf{u}_0 = \mathbf{v}_0 \\ \mathbf{A}\mathbf{v}_k = \mathbf{u}_{k-1} \\ m_k = \max(\mathbf{v}_k) \\ \mathbf{u}_k = \mathbf{v}_k/m_k \end{cases} \quad k = 1, 2, \dots$$

易知

$$\lim_{k \rightarrow \infty} \mathbf{u}_k = \frac{\mathbf{x}_n}{\max(\mathbf{x}_n)}, \quad \lim_{k \rightarrow \infty} m_k = \frac{1}{\lambda_n}.$$



解

$$\begin{aligned} \begin{bmatrix} 3 & 1 & -1 & 4 \\ 4 & 0 & 4 & 8 \\ 12 & -3 & 3 & 9 \end{bmatrix} &\xrightarrow{r_1 \leftrightarrow r_3} \begin{bmatrix} 12 & -3 & 3 & 9 \\ 4 & 0 & 4 & 8 \\ 3 & 1 & -1 & 4 \end{bmatrix} \xrightarrow{\begin{matrix} -\frac{1}{3}r_1+r_2 \\ -\frac{1}{4}r_1+r_3 \end{matrix}} \\ \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & 1 & 3 & 5 \\ 0 & 7 & 7 & 7 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \end{bmatrix} &\xrightarrow{r_2 \leftrightarrow r_3} \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & 7 & 7 & 7 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \\ 0 & 1 & 3 & 5 \end{bmatrix} \xrightarrow{-\frac{4}{7}r_2+r_3} \\ \begin{bmatrix} 12 & -3 & 3 & 9 \\ 0 & 7 & 7 & 7 \\ 0 & \frac{7}{4} & -\frac{7}{4} & \frac{7}{4} \\ 0 & 0 & 4 & 4 \end{bmatrix} &. \end{aligned}$$

回代得  $x_1 = 1, \quad x_2 = 2, \quad x_3 = 1.$

最大值  $\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|}$  能否取到? 由定理 2.1 知, 对  $\forall \mathbf{x} \in \mathbf{R}^n$ ,  $\|\mathbf{Ax}\|$  在  $\mathbf{R}^n$  上连续. 记

$$\mathbf{S} = \{\mathbf{y} | \mathbf{y} \in \mathbf{R}^n, \|\mathbf{y}\| = 1\},$$

$\mathbf{S}$  是有界闭集.  $\|\mathbf{Ax}\|$  在  $\mathbf{S}$  上能取到最大值, 设最大值为  $M$ . 即存在  $\mathbf{y}_0 \in \mathbf{S}$  使得

$$\max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = \|\mathbf{Ay}_0\| = M.$$

故对  $\forall \mathbf{x} \in \mathbf{R}^n, \mathbf{x} \neq 0$ , 有  $\frac{\mathbf{x}}{\|\mathbf{x}\|} \in \mathbf{S}$ , 令  $\mathbf{y} = \frac{\mathbf{x}}{\|\mathbf{x}\|}$ , 有

$$\max_{\substack{\mathbf{x} \in \mathbf{R}^n \\ \mathbf{x} \neq 0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \max_{\mathbf{y} \in \mathbf{S}} \|\mathbf{Ay}\| = M.$$

## 5 习题

习题 3 p.120

1, 5(2), 9, 17, 19, 20, 23, 25, 27, 28, 30, 32(1)(2), 34, 39(上机题)